



Simplon Data Analyst

Machine Learning & Classification

Activité 3

next slide



02



Contexte

L'objectif de ce projet est d'analyser les données de prêts bancaires pour identifier les facteurs de risque et construire un modèle capable de détecter les situations à risque. Nous sommes passés par l'exploration des données, leur prétraitement, la comparaison de plusieurs modèles, puis leur interprétation, avec une attention particulière portée aux faux négatifs.

next slide



03

Présentation de l'équipe

Avant la restitution de notre projet, voici la présentation de notre équipe

David

l'IA grandeur nature



Laurie

La boss des données



Zohair

Le maître des modèles



next slide →

04

Les 3 types de modèles utilisés



RÉGRESSION LOGISTIQUE

Un modèle simple et interprétable, utilisé comme modèle de base pour comparer les performances des autres modèles.



ARBRE DE DÉCISION

Un modèle qui construit des règles de décision pour classer les emprunteurs.




RANDOM FOREST

Un ensemble de plusieurs arbres permettant d'obtenir un modèle plus robuste et performant.

next slide →

05



[LIEN VERS NOTRE STREAMLIT](#) →



Simplon Data Analyst

Merci de votre attention !

Avez-vous des questions ?

CrediTrust Finance — Crédit Scoring X

https://creditrust-scoring.streamlit.app

Fork

CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

CrediTrust Finance — Moteur de Crédit Scoring

Projet réalisé dans le cadre de la formation **Data Analyst — Simplon Lyon**, brief "Machine Learning & Classification" pour le client fictif **CrediTrust Finance**.

Objectif métier

Concevoir un moteur de scoring capable de prédire si une demande de prêt doit être **accordée** (Y) ou **refusée** (N), à partir du profil du demandeur (revenus, historique de crédit, situation familiale, zone géographique...).

Priorité métier explicite du brief : réduire les faux négatifs. Un mauvais payeur non détecté coûte plus cher à la banque qu'un bon payeur refusé à tort — le **rappel sur la classe N** (mauvais payeurs) est donc le critère de choix prioritaire, avant l'accuracy globale.

Répartition du travail (trinôme)

- Laurie** — valeurs manquantes catégorielles (remplacement par "Inconnu") + Régression Logistique
- David** — valeurs manquantes numériques (médiane calculée sur train) + Arbre de Décision
- Zohair** — encodage des variables catégorielles + alignement train/test + Random Forest (standard et balanced)

Stack technique

- Python / pandas / scikit-learn
- CoCalc (notebook partagé temps réel)
- Streamlit (ce dashboard)
- 4 modèles comparés, 1 modèle final retenu

CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données**
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites



Exploration des données (EDA)

Lignes

981

Colonnes

13


Doublons

0

Valeurs manquantes (total)

600

Répartition de la variable cible



CrediTrust

Simplon Lyon — Data Analyst


Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

Distributions des variables numériques

Choisir une variable

ApplicantIncome



Loan_Status selon les variables catégorielles

CrediTrust


Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

Choisir une variable catégorielle

Credit_History



Corrélation entre variables numériques

CrediTrust


Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

Credit_History

Corrélation entre variables numériques



CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement**
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites



Prétraitement des données

1. Séparation train / test

```
train_test_split (80/20, stratifié sur Loan_Status , random_state=42 )
```

Lignes train

491

Lignes test

123

2. Valeurs manquantes catégorielles

Colonnes concernées: `Gender`, `Married`, `Dependents`, `Self_Employed`.

Remplacement par la catégorie "**Inconnu**" plutôt que le mode, pour ne pas introduire de biais artificiel vers la catégorie majoritaire.

3. Valeurs manquantes numériques

Colonnes concernées: `LoanAmount`, `Loan_Amount_Term`, `Credit_History`.

4. Encodage des variables catégorielles

```
pd.get_dummies ( drop_first=True ) SUR: Gender, Married, Dependents, Education, Self_Employed, Property_Area .
```

Un décalage de colonnes entre train et test (catégories absentes d'un des deux jeux) a été corrigé avec `.align(join='left', fill_value=0)`.

5. Standardisation

`StandardScaler` appliqué **uniquement pour la Régression Logistique** (sensible à l'échelle des variables). Les modèles à base d'arbres (Arbre de Décision, Random Forest) n'en ont pas besoin.

Récapitulatif du pipeline

Données brutes

- split train/test (stratifié)
- imputation catégorielle ('Inconnu')
- imputation numérique (médiane train)
- get_dummies + align
- [StandardScaler] (LogReg uniquement)
- entraînement des 4 modèles

Fork



CrediTrust

Simplon Lyon — Data Analyst

Navigation


- Contexte
- Exploration des donn es
- Pr traitement
- Comparaison des mod les**
- Importance des variables
- Simulateur de pr t
- Recommandations & limites

Comparaison des mod les

	Mod�le	Accuracy	Pr�cision (macro)	Rappel (macro)	Rappel classe N	F1 (macro)
0	R�gression Logistique	0.862	0.898	0.784	0.579	0.815
1	Arbre de D�cision	0.748	0.706	0.709	0.605	0.707
2	Random Forest	0.837	0.825	0.780	0.632	0.797
3	Random Forest (balanced)	0.837	0.815	0.795	0.684	0.804

M trique   visualiser

☒ Rappel classe N ☐ Accuracy ☐ F1 (macro) ☐ Pr cision (macro)



CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles**
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

☒ Rappel classe N ☐ Accuracy ☐ F1 (macro) ☐ Précision (macro)



Modèle final retenu : Random Forest (balanced). Le brief priorise la réduction des faux négatifs (un mauvais payeur non détecté coûte plus cher à la banque qu'un bon payeur refusé à tort), donc le rappel sur la classe N est le critère de choix principal, pas l'accuracy globale. Avec le meilleur rappel classe N du comparatif, ce modèle détecte le mieux les mauvais payeurs — au prix d'une accuracy légèrement inférieure à la Régression Logistique. Un compromis assumé, cohérent avec l'objectif métier.



CrediTrust

Simplon Lyon — Data Analyst


Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables**
- Simulateur de prêt
- Recommandations & limites

Importance des variables — modèle final

Nombre de variables à afficher

10



Matrice de confusion (Random Forest balanced)

CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

Matrice de confusion (Random Forest balanced)



Fork



CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt**
- Recommandations & limites



Simulateur de prêt

Renseigne un profil pour obtenir une décision instantanée du modèle final (Random Forest balanced).

Genre	Indépendant	Revenu du demandeur
Male	Yes	5000
Marié(e)	Zone	Revenu du co-demandeur
Yes	Urban	0
Nombre de personnes à charge	Historique de crédit favorable	Montant du prêt (en milliers)
0	☒ Oui ☐ Non	150
Éducation		Durée du prêt (mois)
Graduate		360

Évaluer la demande



CrediTrust Finance — Crédit Scoring

https://creditrust-scoring.streamlit.app

Conversation

<<

CrediTrust

Simplon Lyon — Data Analyst

Navigation

- Contexte
- Exploration des données
- Prétraitement
- Comparaison des modèles
- Importance des variables
- Simulateur de prêt
- Recommandations & limites

Recommandations et limites

✓ Recommandations

- Déployer le **Random Forest (balanced)** comme moteur de décision, avec revue humaine systématique des cas proches du seuil de décision.
- Fixer un **seuil de probabilité métier** (pas nécessairement 50/50) pour ajuster davantage le compromis précision/rappel selon l'appétit au risque de la banque.
- Suivre le modèle dans le temps (drift) : la distribution des profils demandeurs peut évoluer.
- Compléter par une variable de suivi des remboursements réels pour ré-entraîner périodiquement.

⚠ Limites

- Jeu de données de taille modeste : risque de sur-apprentissage sur certains profils rares.
- Déséquilibre des classes (~69% Y / 31% N) partiellement corrigé par `class_weight='balanced'`, mais pas éliminé.
- La catégorie "Inconnu" (valeurs manquantes) peut masquer un signal réel plutôt que du hasard.
- Le modèle reflète des données historiques : il peut reproduire des biais déjà présents dans les décisions passées (ex. zone géographique, statut marital).
- Pas de validation externe (autre banque, autre période) à ce stade.